

Linguaggi Formali e Traduttori

4.1 Parsing top-down e grammatiche LL(1).

- Sommario
- Strategia per il parsing top-down
- Stringhe annullabili (NULL)
- Esempi di stringhe annullabili
- Inizi di una stringa (FIRST)
- Come calcolare FIRST
- Esempi di calcolo di FIRST
- Seguiti di una variabile (FOLLOW)
- Come calcolare FOLLOW
- Esempi di calcolo di FOLLOW
- Insiemi guida
- Grammatiche LL(1)
- Esempio: espressioni aritmetiche
- Esercizi

È proibito condividere e divulgare in qualsiasi forma i materiali didattici caricati sulla piattaforma e le lezioni svolte in videoconferenza: ogni azione che viola questa norma sarà denunciata agli organi di Ateneo e perseguita a termini di legge.

Sommario

Problema

- Data una grammatica $G = (V, T, P, S)$ e una stringa $w \in T^*$, determinare se

$$S \Rightarrow \alpha_1 \Rightarrow \alpha_2 \Rightarrow \dots \Rightarrow w$$

o, equivalentemente, se esiste un albero sintattico di G con radice S e prodotto w .

- La **costruzione dell'automa** corrispondente a G produce un PDA non deterministico.
- Per alcune G sappiamo che **non è possibile trovare un DPDA**.

In questa lezione

- Identifichiamo una famiglia di grammatiche libere per le quali è possibile costruire riconoscitori (parser) deterministici, cioè che non fanno uso di backtracking.
- Questi parser sono detti **top-down** perché costruiscono l'albero sintattico di w dalla radice (top) verso le foglie (down) o, equivalentemente, cercano una derivazione sinistra per w .

Strategia per il parsing top-down

Data una grammatica $G = (V, T, P, S)$ e una stringa $w \in T^*$, il parser cerca di ottenere una derivazione a sinistra $S \Rightarrow_{lm}^* w$ in cui, al passo i , il parser sa che

$$S \Rightarrow_{lm}^* uA\beta$$

e deve stabilire se

$$uA\beta \Rightarrow_{lm}^* w$$

Ci sono due casi da considerare:

- Se u non è prefisso di w , allora il parser **rifiuta** w .
- Se $w = uav$, allora il parser deve **scegliere** una produzione per riscrivere A

$$A \rightarrow \alpha_1 \mid \cdots \mid \alpha_n$$

e per farlo può usare a come “guida”, a patto che tale simbolo identifichi univocamente l' α_i tale che $\alpha_i\beta \Rightarrow_{lm}^* av$.

Per ogni produzione $A \rightarrow \alpha_i$ occorre saper calcolare gli insiemi di simboli terminali che possono **iniziare** le stringhe derivate da $\alpha_i\beta$ e richiedere che tali insiemi siano disgiunti.

Stringhe annullabili (NULL)

Definizione

Data una grammatica $G = (V, T, P, S)$, diciamo che $\alpha \in (V \cup T)^*$ è **annullabile**, e scriviamo $\text{NULL}(\alpha)$, se e solo se $\alpha \Rightarrow_G^* \varepsilon$, ovvero se α può essere riscritta nella stringa vuota.

Come determinare se una stringa è annullabile

- (1) Se $\text{NULL}(X_1), \dots, \text{NULL}(X_n)$, allora $\text{NULL}(X_1 \cdots X_n)$.
- (2) Se esiste una produzione $A \rightarrow \alpha \in P$ e $\text{NULL}(\alpha)$, allora $\text{NULL}(A)$.

Note

- Come caso particolare di (1) quando $n = 0$ abbiamo $\text{NULL}(\varepsilon)$.
- Combinando (1) e (2) abbiamo che $A \rightarrow \varepsilon \in P$ implica $\text{NULL}(A)$.
- Una stringa che contiene simboli terminali non è mai annullabile.

Esempi di stringhe annullabili

$$A \rightarrow a \mid Bc$$

$$B \rightarrow \varepsilon \mid bB$$

$$C \rightarrow d \mid Cc \mid BB$$

Esempi di stringhe annullabili

$$A \rightarrow a \mid Bc$$

$$B \rightarrow \varepsilon \mid bB$$

$$C \rightarrow d \mid Cc \mid BB$$

- Da $\text{NULL}(\varepsilon)$ e dalla produzione $B \rightarrow \varepsilon$ deduciamo $\text{NULL}(B)$.
- Da $\text{NULL}(B)$ e dalla produzione $C \rightarrow BB$ deduciamo $\text{NULL}(C)$.
- Da $\text{NULL}(B)$ e $\text{NULL}(C)$ deduciamo $\text{NULL}(BC)$.
- Da $\neg\text{NULL}(a)$ e $\neg\text{NULL}(Bc)$ deduciamo $\neg\text{NULL}(A)$.

Inizi di una stringa (FIRST)

Definizione

Data una grammatica $G = (V, T, P, S)$ e una stringa $\alpha \in (V \cup T)^*$, indichiamo con $\mathbf{FIRST}(\alpha)$ gli **inizi** di α , ovvero l'insieme dei simboli terminali che possono trovarsi all'inizio delle stringhe derivate da α . Formalmente:

$$\mathbf{FIRST}(\alpha) \stackrel{\text{def}}{=} \{a \in T \mid \alpha \Rightarrow_G^* a\beta\}$$

Attenzione

Il libro di testo usa un'unica funzione $\mathbf{FIRST}_{\text{libro}}$ che combina \mathbf{NULL} e \mathbf{FIRST} così:

$$\mathbf{FIRST}_{\text{libro}}(\alpha) = \begin{cases} \mathbf{FIRST}(\alpha) \cup \{\varepsilon\} & \text{se } \mathbf{NULL}(\alpha) \\ \mathbf{FIRST}(\alpha) & \text{altrimenti} \end{cases}$$

In pratica, l'approccio seguito dal libro ammette il simbolo speciale ε tra gli inizi di α per indicare il fatto che α è annullabile. Noi abbiamo definito un predicato $\mathbf{NULL}(\alpha)$ apposito mentre $\mathbf{FIRST}(\alpha)$ contiene solo simboli terminali.

Come calcolare FIRST

È possibile calcolare $\text{FIRST}(\alpha)$ per induzione su α , usando le seguenti regole:

$$\begin{aligned}\text{FIRST}(\varepsilon) &= \emptyset \\ \text{FIRST}(a) &= \{a\} \\ \text{FIRST}(A) &= \bigcup_{A \rightarrow \alpha} \text{FIRST}(\alpha) \\ \text{FIRST}(X\alpha) &= \begin{cases} \text{FIRST}(X) \cup \text{FIRST}(\alpha) & \text{se } \text{NULL}(X) \\ \text{FIRST}(X) & \text{altrimenti} \end{cases}\end{aligned}$$

Attenzione

Applicando le regole qui sopra, può capitare di arrivare a equazioni della forma

$$\text{FIRST}(A) = \text{FIRST}(A) \cup \mathcal{S}$$

dove \mathcal{S} è un insieme di terminali. Questa equazione si può semplificare a

$$\text{FIRST}(A) = \mathcal{S}$$

in quanto siamo interessati a ottenere il più piccolo insieme di terminali con la proprietà descritta nella [slide precedente](#).

Esempi di calcolo di FIRST

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

Esempi di calcolo di FIRST

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

Variabili annullabili

- $\text{NULL}(A)$
- $\text{NULL}(D)$

Calcolo di FIRST di tutte le variabili

- $\text{FIRST}(B) = \text{FIRST}(b) = \{b\}$
- $\text{FIRST}(A) = \text{FIRST}(\varepsilon) \cup \text{FIRST}(a) = \{a\}$
- $\text{FIRST}(S) = \text{FIRST}(Ac) \cup \text{FIRST}(Ba) = \text{FIRST}(A) \cup \text{FIRST}(c) \cup \text{FIRST}(B) = \{a, b, c\}$
- $\text{FIRST}(C) = \text{FIRST}(a) \cup \text{FIRST}(Cb) = \{a\} \cup \text{FIRST}(C) = \{a\}$
- $\text{FIRST}(D) = \text{FIRST}(\varepsilon) \cup \text{FIRST}(d) \cup \text{FIRST}(Db) = \{d\} \cup \text{FIRST}(D) \cup \text{FIRST}(b) = \{b, d\}$

Seguiti di una variabile (FOLLOW)

Definizione

Data una grammatica $G = (V, T, P, S)$ e una variabile $A \in V$, indichiamo con $\text{FOLLOW}(A)$ i **seguiti** di A , ovvero l'insieme dei simboli terminali che possono seguire A in una forma sentenziale. Formalmente:

$$\text{FOLLOW}(A) \stackrel{\text{def}}{=} \{a \in T \mid S \Rightarrow_G^* \alpha A a \beta\}$$

Attenzione

- Per convenzione aggiungeremo una sentinella $\$$ ai seguiti del simbolo iniziale S .
- In questo modo il parser può capire quando è arrivato alla fine della stringa da riconoscere.

Come calcolare FOLLOW

Il calcolo di **FOLLOW** si effettua in due fasi.

Fase 1

In questa fase si annotano relazioni di appartenenza ed inclusione insiemistica secondo il seguente algoritmo:

- Annotare $\$ \in \text{FOLLOW}(S)$.
- Ripetere i passi seguenti per ogni produzione e per ogni variabile nel corpo di queste:
 1. Se $A \rightarrow \alpha B \beta$, allora annotare $\text{FIRST}(\beta) \subseteq \text{FOLLOW}(B)$.
 2. Se $A \rightarrow \alpha B \beta$ e $\text{NULL}(\beta)$, allora annotare $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$.

Caso particolare di (2): se $A \rightarrow \alpha B$, allora annotare $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$.

Fase 2

Si determinano i seguiti propagando i simboli terminali (e $\$$) rispettando l'ordine delle inclusioni insiemistiche \subseteq che sono state annotate.

Per grammatiche complesse può essere utile fare una tabella con due colonne, l'elenco di tutte le variabili nella prima ed i seguiti corrispondenti alle variabili nella seconda.

Esempi di calcolo di FOLLOW

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

Esempi di calcolo di FOLLOW

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

Fase 1

- $\$ \in \text{FOLLOW}(S)$
- $\text{FIRST}(c) \subseteq \text{FOLLOW}(A)$
- $\text{FIRST}(a) \subseteq \text{FOLLOW}(B)$
- $\text{FIRST}(b) \subseteq \text{FOLLOW}(C)$
- $\text{FIRST}(b) \subseteq \text{FOLLOW}(D)$

Fase 2

X	$\text{FOLLOW}(X)$
S	$\{\$ \}$
A	$\{c\}$
B	$\{a\}$
C	$\{b\}$
D	$\{b\}$

Insiemi guida

Definizione

Data una grammatica $G = (V, T, P, S)$ e una produzione $A \rightarrow \alpha$, indichiamo con $\text{GUIDA}(A \rightarrow \alpha)$ l'**insieme guida** di $A \rightarrow \alpha$, ovvero l'insieme

$$\text{GUIDA}(A \rightarrow \alpha) \stackrel{\text{def}}{=} \begin{cases} \text{FIRST}(\alpha) \cup \text{FOLLOW}(A) & \text{se } \text{NULL}(\alpha) \\ \text{FIRST}(\alpha) & \text{altrimenti} \end{cases}$$

Intuizione

Un parser predittivo che sceglie di riscrivere la variabile A usando la produzione $A \rightarrow \alpha$ si aspetta di leggere nella stringa di input uno dei simboli nell'insieme guida di $A \rightarrow \alpha$.

Sono due i casi da considerare:

1. Il simbolo è uno degli inizi di α , oppure
2. α è annullabile ed il simbolo è uno dei seguiti di A .

Grammatiche LL(1)

Definizione

Diciamo che una grammatica $G = (V, T, P, S)$ è LL(1) se, per ogni coppia di produzioni distinte $A \rightarrow \alpha$ e $A \rightarrow \beta$ in P , abbiamo che

$$\text{GUIDA}(A \rightarrow \alpha) \cap \text{GUIDA}(A \rightarrow \beta) = \emptyset$$

Intuizione

Noto il simbolo da riscrivere A , note le produzioni $A \rightarrow \beta_1 \mid \dots \mid \beta_n$ e noto il prossimo simbolo terminale a nella stringa da riconoscere, in una grammatica LL(1) esiste al massimo una produzione “giusta” tale che $a \in \text{GUIDA}(A \rightarrow \beta_i)$ dunque il parser predittivo identifica univocamente la produzione $A \rightarrow \beta_i$ a partire da a .

Cosa c'è nel nome LL(1)

- L \rightarrow la stringa in input viene analizzata da sinistra (left) a destra;
- L \rightarrow il parser cerca di costruire una derivazione canonica sinistra (leftmost);
- 1 \rightarrow il parser usa un solo simbolo terminale della stringa per scegliere la produzione.

Esempio: espressioni aritmetiche

$$\begin{aligned}E &\rightarrow TE' \\E' &\rightarrow +TE' \mid \varepsilon \quad \text{NULL}(E') \\T &\rightarrow FT' \\T' &\rightarrow *FT' \mid \varepsilon \quad \text{NULL}(T') \\F &\rightarrow (E) \mid \text{id}\end{aligned}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{+\} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{*\} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{)\} = \text{FIRST}()) \subseteq \text{FOLLOW}(E)$

Esempio: espressioni aritmetiche

$$\begin{aligned}E &\rightarrow TE' \\E' &\rightarrow +TE' \mid \varepsilon \quad \text{NULL}(E') \\T &\rightarrow FT' \\T' &\rightarrow *FT' \mid \varepsilon \quad \text{NULL}(T') \\F &\rightarrow (E) \mid \text{id}\end{aligned}$$

$$\begin{aligned}\text{FIRST}(E) &= \text{FIRST}(T) = \{ (, \text{id} \} \\ \text{FIRST}(E') &= \{ + \} \\ \text{FIRST}(T) &= \text{FIRST}(F) = \{ (, \text{id} \} \\ \text{FIRST}(T') &= \{ * \} \\ \text{FIRST}(F) &= \{ (, \text{id} \}\end{aligned}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{ + \} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{ * \} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{) \} = \text{FIRST}(F) \subseteq \text{FOLLOW}(E)$

Esempio: espressioni aritmetiche

$$\begin{aligned}E &\rightarrow TE' \\E' &\rightarrow +TE' \mid \varepsilon \quad \text{NULL}(E') \\T &\rightarrow FT' \\T' &\rightarrow *FT' \mid \varepsilon \quad \text{NULL}(T') \\F &\rightarrow (E) \mid \text{id}\end{aligned}$$

$$\begin{aligned}\text{FIRST}(E) &= \text{FIRST}(T) = \{ (, \text{id} \} \\ \text{FIRST}(E') &= \{ + \} \\ \text{FIRST}(T) &= \text{FIRST}(F) = \{ (, \text{id} \} \\ \text{FIRST}(T') &= \{ * \} \\ \text{FIRST}(F) &= \{ (, \text{id} \}\end{aligned}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{ + \} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{ * \} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{) \} = \text{FIRST}()) \subseteq \text{FOLLOW}(E)$

X	$\text{FOLLOW}(X)$
E	$\$,)$
E'	$\$,)$
T	$\$,), +$
T'	$\$,), +$
F	$\$,), +, *$

Esercizi

1. Calcolare gli insiemi guida della grammatica nella [slide 14](#). La grammatica è LL(1)?
2. Calcolare gli insiemi guida della seguente grammatica e determinare se è LL(1).

$$A \rightarrow BC \mid D$$

$$B \rightarrow \varepsilon \mid a$$

$$C \rightarrow b \mid cCc$$

$$D \rightarrow \varepsilon \mid CD$$

3. Ripetere l'esercizio precedente per la grammatica

$$S \rightarrow \text{if } E \text{ then } SS' \text{ fi} \mid \text{skip}$$

$$S' \rightarrow \text{else } S \mid \varepsilon$$

$$E \rightarrow \text{true} \mid \text{false}$$

in cui S , S' ed E sono variabili e **if**, **then**, ... sono terminali.

4. Ripetere l'esercizio precedente dopo aver rimosso il terminale **fi** dalla grammatica.